Nama : Rizki Wahyu Widodo

NIM : 23031554242

Mata kuliah : Graf Sains Data 2023E

UTS Graf Sains Data

Laporan ini merangkum pengolahan data RetailRocket pada uts_gsd.ipynb. Periode P1 digunakan untuk membangun graf dan rekomendasi, sedangkan P2 digunakan untuk evaluasi.

1. Pertanyaan Pendahuluan

Notebook terhubung ke database uts pada Neo4j lokal melalui neo4j://127.0.0.1:7687. Database ini berbeda dari database neo4j pada contoh pertemanan Arthur. Contoh tersebut tidak dijalankan dalam notebook yang dianalisis.

Perintah Cypher yang digunakan mencakup CREATE CONSTRAINT untuk menjaga keunikan ID, UNWIND untuk memproses batch, MERGE untuk membuat atau mencocokkan simpul, CREATE untuk menambah relasi, serta MATCH dan RETURN untuk membaca graf. Relasi KNOWS pada contoh Arthur berarah; arah sebaliknya tidak terbentuk otomatis.

2 Soal UTS

2.1 Wrangling dan EDA

1 Penentuan periode

Timestamp Unix pada events.csv dikonversi dari milidetik ke waktu UTC. Batas akhir setiap periode dibaca secara inklusif sampai akhir hari melalui pembatas eksklusif pada pukul 00.00 hari berikutnya. Kedua periode tidak saling bertumpang tindih.

Periode	Tanggal	Baris	Waktu paling awal UTC	Waktu paling akhir UTC
P1 training	4 Jun–23 Agu 2015	1.645.611	4 Jun 00:00:00,993	23 Agu 23:59:56,475
P2 testing	24 Agu–13 Sep 2015	385.656	24 Agu 00:00:12,490	13 Sep 23:59:56,743

Berkas sumber memuat 2.756.101 interaksi dari 3 Mei sampai 18 September 2015. Sebanyak 724.834 baris berada di luar kedua fold. Pemeriksaan notebook menghasilkan “P1 selesai sebelum P2 mulai: True”.

2. Penyimpanan CSV dan impor ke Neo4j

P1 tersimpan sebagai output/events_p1_train.csv dan P2 sebagai output/events_p2_test.csv. Hanya P1 yang diimpor ke database uts; P2 disimpan untuk evaluasi. Perincian jenis interaksinya sebagai berikut.

Periode	User unik	Item unik	VIEWED	ADDED TO CART	BOUGHT
P1	858.124	189.066	1.590.454	41.599	13.558
P2	218.615	94.183	372.442	10.045	3.169

Impor dilakukan dalam 1.646 batch berisi hingga 1.000 baris dan selesai sekitar 2 menit 57 detik. Setiap baris membentuk relasi interaksi antara User dan Item. Kode mengosongkan database uts sebelum impor, sehingga menjalankan ulang sel tersebut akan membangun ulang graf.

3. Komposisi subgraf

```
MATCH (n)
RETURN labels(n)[0] AS jenis_simpul, count(n) AS jumlah
ORDER BY jumlah DESC;


MATCH ()-[r]->()
RETURN type(r) AS jenis_relasi, count(r) AS jumlah
```

ORDER BY jumlah DESC;

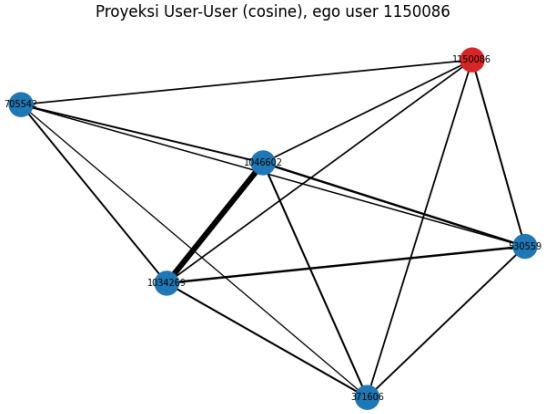
Query pertama mengelompokkan simpul menurut label pertamanya. Query kedua mengelompokkan relasi menurut jenisnya. Python API menampilkan 858.124 simpul User dan 189.066 simpul Item, sehingga totalnya 1.047.190 simpul. Jumlah relasi VIEWED adalah 1.590.454, ADDED_TO_CART 41.599, dan BOUGHT 13.558. Total 1.645.611 relasi sama dengan jumlah baris P1. Jenis VIEWED mendominasi, yaitu sekitar 96,65% interaksi P1.

4. VSM User

Setiap user direpresentasikan sebagai vektor item. Bobot VIEWED, ADDED_TO_CART, dan BOUGHT berturut-turut adalah 1, 2, dan 3. Interaksi berulang pada pasangan user–item dijumlahkan, lalu vektor dinormalisasi untuk menghitung cosine similarity.

Karakteristik VSM User	Nilai
Ukuran matriks	858.124 × 189.066
Pasangan bukan nol (nnz)	1.285.103
Densitas	0,000792%
Sparsitas	99,999208%
Item per user, median / rata-rata	1 / 1,497573
Item per user, maksimum	3.328
User dengan satu item	80,529387%

Matriks sangat jarang: lebih dari 80% user hanya memiliki satu pasangan user–item. Ego graph user 1150086 memuat enam simpul dan 15 sisi. Kepadatan sampel kecil ini tidak mewakili seluruh proyeksi.



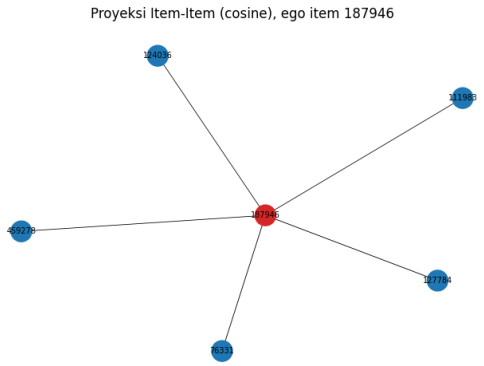
User acuan 1150086 dipilih karena memiliki jumlah item berbeda terbanyak. Sampel ego graph menampilkan enam simpul dengan 15 sisi, yaitu seluruh pasangan di antara enam simpul tersebut. Ketebalan sisi mengikuti cosine, sehingga pasangan tetangga tertentu tampak lebih kuat dibanding hubungan user acuan dengan tetangganya. Kepadatan gambar lokal ini tidak mewakili kepadatan keseluruhan proyeksi.

5. VSM Item

VSM Item merupakan transpose VSM User: setiap baris mewakili item dan setiap kolom mewakili user.

Karakteristik VSM Item	Nilai
Ukuran matriks	189.066 × 858.124
Pasangan bukan nol (nnz)	1.285.103
Densitas	0,000792%
Sparsitas	99,999208%
User per item, median / rata-rata	2 / 6,797113
User per item, maksimum	1.884
Item dengan satu user	38,670623%

Dibandingkan VSM User, distribusi item memiliki lebih sedikit baris dengan hanya satu elemen bukan nol. Hal itu berarti lebih banyak item diakses oleh beberapa user, walaupun matriks keseluruhan tetap sangat jarang.



Item acuan 187946 dipilih berdasarkan jumlah user berbeda terbanyak. Ego graph menampilkan enam simpul dan lima sisi: tiap tetangga terhubung ke item acuan, sedangkan lima tetangga tidak saling terhubung pada sampel ini. Ini menunjukkan user yang menghubungkan item acuan dengan masing-masing tetangga tidak menghasilkan kemiripan positif di antara kelima tetangga tersebut.

6. Perbandingan proyeksi

Ukuran	User–User	Item–Item
Jumlah simpul	858.124	189.066
Batas atas sisi yang dihitung	36.894.934	19.935.339
Sisi maksimal graf lengkap	368.187.970.626	17.872.881.645
Pencarian top k per acuan	42,739 ms	47,359 ms

Item-Item lebih hemat menurut batas atas jumlah sisi, sedangkan User–User sedikit lebih cepat pada uji pencarian top-k. Batas atas tersebut dapat menghitung pasangan yang sama berulang kali, sehingga bukan jumlah sisi unik. Notebook tetap memakai User–User untuk similarity dan KNN berbasis user.

7. Perhitungan similarity

Lima tetangga dengan cosine tertinggi untuk user 1150086 adalah:

Peringkat	User tetangga	Cosine
1	530559	0,234013
2	371606	0,196128
3	705542	0,180167
4	1034269	0,178341
5	1046602	0,178341

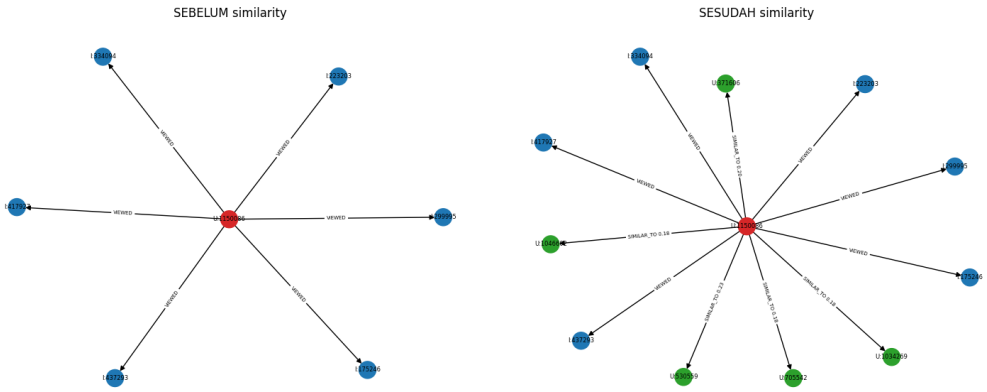
Nilai ini ditulis ke Neo4j sebagai lima relasi SIMILAR_TO dari user acuan. Properti score menyimpan cosine dan metric menyimpan nama metode. Pembacaan ulang hasil dari graf menyatakan kecocokan dengan perhitungan Python.

```
MATCH (r:User {visitorId: $ref})-[s:SIMILAR_TO]->(n:User)
RETURN n.visitorId AS User, s.score AS cosine
ORDER BY s.score DESC, n.visitorId ASC
LIMIT 5;
```

Pada eksekusi notebook, parameter $ref diisi dengan string "1150086". Properti simpul bernama visitorId; penggunaan properti User sebagai pengganti visitorId tidak sesuai dengan struktur graf.

8 Kondisi sebelum dan sesudah similarity

Penambahan lima SIMILAR_TO menaikkan total relasi dari 1.645.611 menjadi 1.645.616 tanpa mengubah relasi interaksi. Gambar sebelum dan sesudah merupakan sampel visualisasi NetworkX; posisi simpul pada kedua panel tidak menunjukkan perubahan jarak yang dapat dibandingkan.



Relasi	Sebelum	Sesudah
VIEWED	1.590.454	1.590.454
ADDED_TO_CART	41.599	41.599
BOUGHT	13.558	13.558
SIMILAR_TO	0	5

Ketiga jenis relasi interaksi tetap berjumlah 1.645.611. Setelah penambahan lima SIMILAR_TO, total relasi menjadi 1.645.616. Gambar “sebelum” hanya memuat sampel tujuh relasi interaksi, sedangkan panel sesudah menambah tetangga similarity. Posisi simpul dua panel dihitung terpisah oleh tata letak NetworkX, sehingga yang dibandingkan adalah keberadaan relasi, bukan jarak geometris dalam gambar.

```
MATCH p = (u:User {visitorId: '1150086'})
      -[:VIEWED|ADDED_TO_CART|BOUGHT]->(:Item)
RETURN p LIMIT 7;


MATCH p = (u:User {visitorId: '1150086'})
      -[:SIMILAR_TO]->(:User)
RETURN p;
```

Dua query terakhir dapat dipakai di Neo4j Browser untuk menampilkan graf masing-masing. Query pertama tetap dapat dijalankan sesudah similarity tertulis karena hanya memilih relasi interaksi; ia bukan rekaman keadaan database sebelum penulisan jika tangkapan layar pada waktu itu belum dibuat.

2.2 Analytics

Rekomendasi dihitung dari P1. Item baru yang diakses user pada P2 menjadi acuan relevansi. User evaluasi dipilih dari kelompok yang memiliki interaksi baru di P2, sehingga hasilnya tidak mewakili seluruh user training.

1. KNN dan tiga item iklan

Notebook memilih hingga lima tetangga dengan cosine positif, menjumlahkan skor item mereka, lalu mengecualikan item yang sudah diakses user target pada P1. Pemilihan user menggunakan *seed* 42.

Dari 17.284 user yang muncul pada P1 dan P2, sebanyak 6.222 memenuhi syarat minimal dua item P1 dan satu item baru P2. Sebanyak 878 di antaranya memiliki sedikitnya tiga kandidat rekomendasi. User terpilih adalah 1126031.

Tetangga KNN	Cosine
1328447	0,707107
508061	0,707107
849681	0,707107
852154	0,500000
921539	0,408248

Dari lima tetangga tersebut, fungsi KNN menghasilkan tiga item dengan skor positif. Ketiganya menjadi item yang diiklankan. Fungsi meminta paling banyak lima rekomendasi, tetapi pada output ini hanya tiga item yang memenuhi syarat skor positif; posisi keempat dan kelima tidak terisi.

Peringkat	Item iklan	Skor KNN
1	3112	0,500000
2	249444	0,408248
3	27897	0,408248

2. Hit@5 dan NDCG@5

Ground truth untuk user 1126031 terdiri dari satu item baru pada P2, yaitu 269088. Tidak satu pun dari tiga item yang direkomendasikan sama dengan item tersebut. Hit@5 bernilai 0 karena tidak ada item relevan dalam daftar rekomendasi yang tersedia. Dua posisi kosong pada daftar top-5 tidak memberi relevansi.

Peringkat	Item	Relevan
1	3112	0
2	249444	0
3	27897	0

NDCG@5 mempertimbangkan posisi item relevan. Karena tidak ada item yang cocok, DCG@5 = 0. User memiliki satu item relevan, sehingga nilai idealnya menempatkan item itu di urutan pertama: IDCG@5 = $1/\log_2(2) = 1$. Hasilnya NDCG@5 = 0/1 = 0.

Hit@5 dan NDCG@5 yang bernilai nol menggambarkan satu user dari kelompok kandidat yang disaring memakai P2; notebook belum mengukur rata-rata seluruh user. Seluruh angka dan gambar diambil dari output uts_gsd_(3).ipynb. Penjelasan.pdf digunakan hanya sebagai contoh susunan penulisan.